

SOLUTIONS CONSULTING · 产品白皮书

Claude 全线产品 详解手册

从模型层到企业落地——一份给客户的完整产品全景

编制视角：解决方案工程师 (SC) → 客户

覆盖范围：模型 / 消费端 / 开发者 / 企业 / 分发渠道

数据时点：2026 年 6 月（旗舰 Opus 4.8）

说明：价格与功能更新频繁，决策前请以官网为准

目录

- 01 产品全景：先把"Claude"这个词拆开
- 02 模型层：Opus / Sonnet / Haiku 三档怎么选
- 03 消费端产品：Free / Pro / Max / Team / Enterprise
- 04 Claude.ai 内置能力：Artifacts、Projects、记忆等
- 05 开发者产品：API 平台与核心能力
- 06 Claude Code 与 Agent 类产品
- 07 分发渠道：直连 vs Bedrock vs Vertex vs Azure
- 08 成本杠杆：缓存、批处理、长上下文
- 09 选型决策树：按客户场景对号入座
- 10 常见客户异议与应对

01 产品全景：先把"Claude"这个词拆开

客户常把"Claude"当成一个聊天网站。作为 SC，第一步是帮客户建立分层心智模型——这决定了后面所有的选型对话。

"Claude" 不是单一产品，而是一个由 Anthropic 提供的、从底层模型到上层应用的产品族。理解它最有效的方式是分成**四层**：模型层、消费端应用、开发者平台、企业能力。同一个模型（比如 Opus 4.8）会同时出现在订阅产品和 API 里——客户买的"套餐"决定的是**怎么用、用多少、什么合规级别**，而不是"用哪个大脑"。

四层结构

层级	包含什么	客户买它解决什么问题
模型层	Opus 4.8 / Sonnet 4.6 / Haiku 4.5	底层智能。所有上层产品共享同一批模型
消费端	Claude.ai 网页/桌面/移动端； Free / Pro / Max 订阅	个人即开即用，无需写代码
开发者	Claude API、Claude Code、 Agent SDK	把模型嵌入自己的产品/工作流
企业	Team / Enterprise 套餐、SSO、 数据驻留、合规控制	组织级部署、安全、计费、治理

SC 视角

客户问"Claude 多少钱"时，先别报价。先确认他在哪一层——是个人想用（消费端订阅），还是要嵌入产品（API 按 token），还是组织采购（Enterprise 定制）。这三个问题的答案完全不同，混在一起报价是新人最常犯的错。

一个关键区分：订阅 vs 按量

消费端套餐（Pro/Max/Team）是**固定月费 + 模糊的使用额度**，适合人坐在屏幕前交互式使用。API 是**按 token 计费**，适合程序化调用、嵌入应用、跑批量任务。两者的模型是同一批，但计费逻辑、SLA、合规承诺都不一样。

02 模型层：三档怎么选

Anthropic 维持一个"三档"心智：旗舰、均衡、高速。客户 90% 的选型纠结，本质是在这三档之间权衡质量与成本。

当前在售的三个主力档位是 **Opus**（最强推理）、**Sonnet**（性价比均衡，多数生产负载的默认）、**Haiku**（最快最便宜，高并发场景）。一个好记的规律：所有档位的输出价都是输入价的 **5 倍**，预算估算时输入成本乘 5 就是输出上限。

当前主力模型对照（API 标准价，每百万 token）

模型	定位	输入价	输出价	上下文
Opus 4.8 最新旗舰	最强推理、写作、复杂 Agent	\$5.00	\$25.00	1M
Opus 4.7	上一代旗舰，仍可选	\$5.00	\$25.00	1M
Sonnet 4.6 默认推荐	智能与成本的最佳平衡	\$3.00	\$15.00	1M
Haiku 4.5	速度优先、高并发、低成本路由	\$1.00	\$5.00	—

数据时点 2026 年 6 月。Opus 4.8 于 5 月 28 日发布，价格与 4.7 持平；Fast Mode 价格较 4.7 大幅下调。三档的具体价格请以 anthropic.com/pricing 为准。

关键认知：Opus 不再是"奢侈品"

历史上 Opus 曾是 \$15/\$75 的高价档，只用于最敏感的任务。现在 Opus 降到 \$5/\$25，与 Sonnet 的差距从 5 倍缩到约 **1.67 倍**。这意味着选型逻辑变了：现在只要有证据表明质量差异能减少下游返工，升到 Opus 就是合理的。

Adaptive Thinking（自适应思考）

最新的 Opus 4.8 / 4.7 不再用"扩展思考"开关，而是由模型自己决定是否深度推理——称为 Adaptive Thinking。较老的 Sonnet 4.6、Haiku 4.5 仍用扩展思考机制。对客户意义：新旗舰不需要你手动调"思考预算"，但成本会因任务复杂度浮动。

SC 视角

给客户的默认建议：**Sonnet 4.6 + 提示缓存**作为生产默认，Haiku 做低成本路由（分类、抽取、简单问答），Opus 留给真正吃质量的请求（复杂 Agent、长文写作、多文件代码重构）。不要让客户一上来全用 Opus——成本会失控，而且很多场景 Sonnet 已经够好。

迁移提醒：从 Opus 4.6 升到 4.7/4.8 时，4.7 引入的新分词器对同样的文本可能多产生最多 35% 的 token。单价没变，但单次请求的实际成本可能上升。4.7→4.8 是纯配置切换，无额外分词器代价。

03 消费端产品：五个套餐

这是客户最容易自己看懂、但也最容易选错的部分。核心变量是"使用额度"和"组织级控制"。

消费端有五个套餐：面向个人的 **Free / Pro / Max**，面向组织的 **Team / Enterprise**。所有付费套餐都能用到最新模型（含 Opus 4.8），区别在于**用量上限、协作功能、安全合规**，而不是模型本身。

套餐对照

套餐	价格	适合谁	关键特征
Free	\$0	偶尔使用、试用	网页/iOS/安卓/桌面全端；含基础对话、网页搜索、Artifacts；额度最低，高峰期受限
Pro	\$20/月	个人专业用户	约 5 倍于 Free 的额度；写作/编码/研究/文档分析的默认付费档
Max 5×	\$100/月	经常撞 Pro 上限的重度用户	5 倍 Pro 容量；适合长时间编码/研究会话
Max 20×	\$200/月	每天高强度依赖	20 倍容量；过载时段优先路由；Opus 高频使用几乎不撞日限
Team	\$30/坐席 (年付 \$25)	5-150 人组织	SAML SSO、集中计费、管理后台、M365 集成、默认不用对话训练模型；共享 Projects
Enterprise	定制	大型组织	平台费与用量费分开计；最高合规/安全控制；可能含量价折扣

价格时点 2026 年 6 月。部分来源列出 Team Premium（约 \$125/坐席，5 倍 Team 标准用量）。具体以官网与销售报价为准。

用量额度的真相

Anthropic 不公布精确的"每天多少条消息"。额度按**滚动 5 小时窗口**重置，且会随模型、提示长度、附件而浮动。这是客户最容易困惑的点——你要管理预期：用量是"够正常使用、撞上限说明该升档"，而不是一个可精确预算的数字。

SC 视角

组织客户的水分岭很清晰：**需要共享 Projects + 管理后台但不需要完整企业合规 → Team**；**需要 SSO 强制、数据驻留、审计、定制 DPA、量价 → Enterprise**。个人开发者如果是"自己用 + 偶尔嵌入小工具"，Pro/Max 比 API 更划算；一旦要程序化高频调用，就该转 API。

04 Claude.ai 内置能力

套餐之外，Claude.ai 这个界面本身有一批能力。客户买套餐时其实也在买这些工具，值得逐项讲清楚。

Artifacts（工件）

在对话旁边开一个独立窗口，实时渲染代码、文档、网页、图表、React 组件。客户可以让 Claude 做一个可交互的工具，直接在界面里运行。进阶能力包括用 Claude API 驱动的"AI 应用"（即在 Artifact 内再调用模型），以及可跨会话保存数据的持久化存储。

Projects（项目）

把相关对话、文件、自定义指令归到一个项目下，共享上下文。Team 及以上可在组织内共享 Projects——这是团队协作的核心载体。

记忆与历史引用

Claude 可以引用过往对话、从历史中生成记忆，让交互更连贯。可在设置里开关。注意：Incognito（隐身）对话不写入记忆。

其他可开关的功能

- **网页搜索 / 深度研究**：实时检索并综合多来源信息
- **代码执行与文件创建**：在沙箱里跑代码、生成 Word/PPT/Excel/PDF 等可下载文件
- **连接器（MCP）**：接入第三方应用与服务（日历、邮件、任务、设计工具等）

Claude 的"应用版"工具

Anthropic 还提供一组面向具体工作流的产品：**Claude in Chrome**（浏览代理）、**Claude in Excel**（表格代理）、**Claude in PowerPoint**（幻灯片代理）、**Claude Design**（画布+设计工具）。还有 **Claude Cowork**——面向非开发者的桌面知识工作代理，可调用上述工具。这些多为 Beta，能力和可用性会变。

SC 视角

当客户说"我们已经在用 ChatGPT 了"，这些内置能力（尤其 Artifacts + Projects + 连接器）是差异化对话的切入点——重点不是"谁的模型更聪明"，而是"在你的实际工作流里，工件化输出和项目级上下文管理能省多少返工"。

05 开发者产品：API 平台

这是你（SC）和客户技术团队对话最深的地方。客户要把 Claude 嵌进自己的产品时，谈的全是 API 的能力边界。

Claude API 是标准的 `/v1/messages` 端点，按 token 计费。它不只是“发问题收答案”——围绕它有一整套生产能力：工具调用、批处理、提示缓存、流式输出、视觉/PDF 输入、长上下文、服务端工具（网页搜索、代码执行）。

核心能力清单

能力	说明	典型客户用途
工具调用 / Function Calling	模型按需调用你定义的函数	查数据库、调内部 API、触发动作
批处理 Batch API	异步批量任务，价格立减 50%	离线打标、大规模内容生成
提示缓存 Prompt Caching	缓存命中部分输入成本降 90%	长系统提示、固定知识库前缀
流式输出 Streaming	逐 token 返回	聊天类前端的实时体验
视觉 / PDF 输入	图像与 PDF 作为输入（base64）	文档抽取、截图理解
1M 长上下文	Opus/Sonnet 标准价支持百万 token	整本手册、大代码库一次喂入
服务端工具	网页搜索、代码执行等托管工具	免自建检索/执行基建（按次另计费）

模型字符串（API 调用标识）

客户技术团队会问“调用时填什么”：`claude-opus-4-8`、`claude-opus-4-7`、`claude-sonnet-4-6`、`claude-haiku-4-5`。会话中可中途切换模型。

关于自助知识：API 的 SDK 用法、速率限制、function calling 细节更新很快。给客户技术团队的最佳实践是直接指向官方文档地图（docs.claude.com），不要凭记忆报参数——这也是你建立专业可信度的方式。

SC 视角

迁移类客户（比如从别家 LLM 转过来）最关心三件事：①工具调用语义是否对齐 ②长上下文是否额外收费（答案：Opus/Sonnet 1M 标准价不加价，这是强卖点）③缓存能省多少。把这三点量化成“按你的负载，月账单从 X 降到 Y”，比讲功能列表有力得多。

06 Claude Code 与 Agent 类产品

编码 Agent 是 Anthropic 增长最快的产品线之一，也是技术决策者最有体感的演示场景。

| Claude Code

一个 Agent 式编码工具，让开发者从命令行、桌面端或移动端把编码任务委派给 Claude。它能读写代码库、跑命令、迭代调试、集成 MCP server。可通过 Claude 移动 App 远程操作。

近期更新（2026 年 5 月）：Anthropic 将所有付费套餐的 Claude Code 5 小时速率上限翻倍，并移除了 Pro/Max 的高峰期限流。对重度编码客户是实质性的体验提升。

| Claude Cowork

面向非开发者的桌面知识工作代理。把"研究→整理→产出文档/表格/幻灯片"这类多步骤工作流交给它，可调用 Chrome、Excel、PPT、Design 等工具。可通过移动 App 远程触发。

| Agent SDK / 服务端工具

对要自建 Agent 的客户，API 侧提供工具调用、服务端托管工具（网页搜索、代码执行）和 MCP 接入。客户可以基于这些搭建自己的领域 Agent，而不必从零造检索和执行基建。

SC 视角

Claude Code 是最好的"先让客户上手"产品——技术团队试一次就有体感。销售路径常常是：开发者自己用 Claude Code 上瘾 → 团队采购 Team → 业务侧要嵌产品 → 转 API/Enterprise。把 Claude Code 当成进入企业的楔子。

07 分发渠道

企业客户的采购、合规、云账单往往绑定在某个云厂商上。模型走哪个渠道，直接影响能不能进客户的采购流程。

Claude 模型可通过四条渠道分发：**Anthropic 直连 API、Amazon Bedrock、Google Cloud Vertex AI、Microsoft Azure AI Foundry**。模型是同一批，渠道决定的是合规边界、数据驻留、计费归属、采购便利性。

渠道	核心价值	适合的客户
Anthropic 直连	第一时间拿到新模型与新功能	要用最新能力、灵活性优先
AWS Bedrock	并入 AWS 账单与 IAM 治理	已重度使用 AWS 的企业
Google Vertex AI	并入 GCP 生态与计费	GCP 客户
Azure AI Foundry	并入 Azure 体系（部分模型已 GA）	微软体系企业

数据驻留与合规

API 侧自 2025 年 8 月起支持 EU 多区域处理（数据驻留）。需要注意：Claude.ai 消费端套餐默认不提供 EU 数据驻留，推理仍路由到 Anthropic 服务器。对合规敏感的金融/医疗/政府客户，还有 US-only 推理选项（约 1.1 倍价格）。EU AI Act 高风险系统义务自 2026 年 8 月 2 日起适用——这是欧洲企业客户的合规时间窗，值得主动提示。

SC 视角

渠道问题往往不是技术问题，是采购问题。当客户说“我们只能走 AWS 采购”，别把它当障碍——Bedrock 渠道让你绕过新供应商准入流程，反而是加速成交的杠杆。先问客户的云归属，再决定主推哪条渠道。

08 成本杠杆

客户对 API "贵不贵"的焦虑，90% 可以用三个杠杆化解。会算账的 SC 比会背价目表的 SC 值钱得多。

决定 API 实际账单的，往往不是头部单价，而是：上下文大小、提示缓存、输出长度、能否走批处理。三个核心杠杆叠加，理论上最多可降 95% 成本。

三大杠杆

杠杆	节省	适用条件
提示缓存	缓存命中输入降 90%	有固定长前缀（系统提示、知识库、文档）反复使用
批处理 Batch	全模型立减 50%	任务可异步、不要求实时返回
模型分层路由	视负载而定	简单任务走 Haiku，复杂任务才升 Sonnet/Opus

一个量化示例

同样 1000 万输入 + 200 万输出的负载：Haiku 4.5 约 \$20，Sonnet 约 \$60，Opus 约 \$100。再叠加缓存和批处理，可在此基础上进一步大幅压缩。给客户算账时，用他真实的月 token 量代入，比报单价有说服力得多。

SC 视角

第一个成本决策永远是"选哪个模型族"，而不是抠微优化。先帮客户把负载分类（哪些必须 Opus、哪些 Sonnet 够用、哪些 Haiku 就行），再上缓存和批处理。顺序反了，客户会先被总价吓退。

09 选型决策树

把前面所有内容压缩成一张"对号入座"表，方便你在客户会议现场直接用。

按客户画像选产品

客户说……	主推	理由
"我个人想用，写东西、查资料"	Pro (\$20)	个人付费默认档，额度够日常
"我天天用，老撞上限"	Max 5× / 20×	长会话、高频不被打断
"我们小团队要协作、共享上下文"	Team	共享 Projects + 管理后台 + SSO
"我们要 SSO 强制、数据驻留、审计"	Enterprise	完整合规与治理，量价折扣
"我要把它嵌进我们产品"	API（直连或云渠道）	按 token、可程序化、可缓存批处理
"我们开发团队想加速写代码"	Claude Code	最快见效的上手产品
"我们只能从 AWS/GCP/Azure 采购"	对应云渠道	并入既有账单与采购流程
"成本敏感、量大、可异步"	Sonnet/Haiku + Batch + 缓存	三杠杆叠加压成本

按任务选模型

任务	模型
分类、抽取、简单问答、高并发路由	Haiku 4.5
多数生产负载、聊天、文档处理、性价比优先	Sonnet 4.6（默认）
复杂 Agent、长文写作、多文件代码重构、最高质量	Opus 4.8

10 常见客户异议与应对

这一节是给你现场用的弹药。每条异议给一个站得住的回应方向，而不是话术模板。

"比 GPT 贵"

承认 Opus 单价确实高于部分竞品。把对话从单价拉到总拥有成本：① Opus/Sonnet 的 1M 上下文标准价不加价，长文档场景反而省；② 缓存+批处理能降最多 95%；③ 输出质量减少的下游返工，往往比 token 差价值钱得多。用客户真实负载算 TCO，而不是比单价。

"我们已经用了别家"

不要正面打模型擂台。切入差异化的工作流能力：Artifacts 的工件化输出、Projects 的项目级上下文、连接器生态、Claude Code 的编码体验。问一个问题："在你们实际流程里，哪一步最费返工？"然后针对性演示。

"用量上限不透明，没法预算"

消费端套餐确实按滚动 5 小时窗口、不公布精确条数——这是事实，别绕。如果客户要可预算的精确成本，那他的真实需求是 API（按 token，完全可算），把他从订阅引导到 API 才是对的。

"合规/数据驻留过不了"

分场景：API 支持 EU 多区域处理；合规敏感行业有 US-only 推理选项；走 Bedrock/Vertex/Azure 可并入既有云的合规框架。先搞清楚客户具体卡在哪个法规，再对应渠道，别笼统说"我们很安全"。

"模型更新太快，怕踩坑"

这其实是优势点。可以给客户 pin 住版本化模型 ID（如 `claude-opus-4-7`）保证稳定，同时随时评估新版。提醒分词器变化（4.6→4.7 可能多 35% token）这类迁移细节，恰恰显示你的专业度。

SC 视角 · 总结

这份文档的底层逻辑：客户买的从来不是"模型"，是"在他的约束下（预算/合规/工作流/团队）能落地的方案"。你的价值不是背产品参数，而是把这四层产品映射到客户的真实约束上。价格和功能会变，这套映射方法不会。

本文档数据时点为 2026 年 6 月，旗舰模型为 Claude Opus 4.8。价格、套餐、功能更新频繁，任何采购或技术决策前请以 anthropic.com/pricing、docs.claude.com 及销售报价为准。文档由解决方案工程视角编制，供客户教育与内部参考使用。