

深度技术参考 • TECHNICAL REFERENCE

Claude 全线产品 技术参考文档

模型规格 • API 技术文档 • 配置详解 • 竞品横向对比

文档类型：深度技术参考（含结构化图表与配置示例）

覆盖：模型层 / API / Claude Code / 缓存与限流 / 竞品对比

数据时点：2026 年 6 月 • 旗舰 Claude Opus 4.8

数据来源：platform.claude.com 官方文档 + 第三方基准

注意：价格/限流/功能更新频繁，生产决策请以官方文档为准

目录

01 产品架构总览

02 模型层：完整技术规格表

三档对比 · 上下文/输出上限 · 知识截止 · 模型 ID · Adaptive Thinking

03 API 技术文档

端点 · 请求结构 · 核心参数 · 工具调用 · 流式 · 错误码

04 限流（Rate Limits）与服务层级

RPM/ITPM/OTPM · 使用层级 · 429 处理 · Priority Tier

05 成本优化：缓存 / 批处理 / 路由

提示缓存配置 · Batch API · Token 计数 · 成本测算

06 Claude Code：安装与配置详解

安装 · 环境要求 · MCP 配置 · effort 参数 · Agent Teams

07 消费端套餐与功能矩阵

08 应用层功能：Artifacts / Projects / MCP 等

09 分发渠道与数据合规

10 竞品横向对比（vs GPT / Gemini）

11 选型决策与整体优缺点

01 产品架构总览

Claude 不是单一产品，而是底层共享同一批模型、上层按用途分化的产品族。

理解 Claude 产品的关键：**同一批模型（Opus 4.8 / Sonnet 4.6 / Haiku 4.5）**同时驱动消费端订阅、API、Claude Code 和各类应用代理。你选择的"产品/套餐"决定的是**访问方式、计费模式、用量边界与合规级别**，而非底层智能本身。

三层架构

层级	产品 / 组件	计费方式	面向
模型层	Opus 4.8 / Sonnet 4.6 / Haiku 4.5； Mythos Preview（受邀）	—（被上层调用）	所有上层共享
应用层	Claude.ai 网页/桌面/移动；Artifacts / Projects / Memory / 连接器； Excel/Word/Chrome 代理；Cowork	订阅（固定月费 + 滚动额度）	个人 / 团队 / 企业终端用户
开发层	Claude API（Messages / Batches / Models / Token Counting）；Claude Code；Managed Agents	按 token（+ 会话运行时，针对 Managed Agents）	开发者 / 集成方

访问入口对照

入口	形态	典型用途
claude.ai / 桌面 / 移动 App	对话界面	交互式使用、写作、研究、原型
Claude API（直连）	REST 端点	嵌入自有产品、程序化调用
Claude Code	CLI / 桌面 / 移动	Agent 式编码、代码库操作
Bedrock / Vertex / Microsoft Foundry	云市场	并入既有云的计费与合规
Claude Platform on AWS	AWS 上的一方平台	用 Claude 原生模型 ID + AWS 计费

02 模型层：完整技术规格表

以下数据来自 platform.claude.com 官方 Models Overview 页（2026 年 6 月）。

2.1 最新三档模型完整规格

规格项	Opus 4.8 旗舰	Sonnet 4.6 默认	Haiku 4.5 高速
定位	最强推理、长程 Agent 编码、高自主任务	速度与智能的最佳平衡	近前沿智能的最快模型
Claude API ID	claude-opus-4-8	claude-sonnet-4-6	claude-haiku-4-5-20251001
API 别名	claude-opus-4-8	claude-sonnet-4-6	claude-haiku-4-5
Bedrock ID	anthropic.claude-opus-4-8	anthropic.claude-sonnet-4-6	anthropic.claude-haiku-4-5-20251001-v1:0
Vertex AI ID	claude-opus-4-8	claude-sonnet-4-6	claude-haiku-4-5@20251001
输入价 / MTok	\$5	\$3	\$1
输出价 / MTok	\$25	\$15	\$5
上下文窗口	1M tokens（Foundry 上为 200k）	1M tokens	200k tokens
最大输出	128k tokens	64k tokens	64k tokens
扩展思考	否	是	是
自适应思考	是	是	否
Priority Tier	是	是	是
相对延迟	中等	快	最快
可靠知识截止	2026 年 1 月	2025 年 8 月	2025 年 2 月
训练数据截止	2026 年 1 月	2026 年 1 月	2025 年 7 月

所有当前模型均支持文本与图像输入、文本输出、多语言与视觉能力。批处理 API 上 Opus 4.8/4.7/4.6 与 Sonnet 4.6 可用 `output-300k-2026-03-24` beta header 将输出上限提至 300k。

2.2 关键技术概念

模型 ID 是固定快照（Pinned Snapshot）

从 4.6 代起，模型 ID 采用无日期格式，但仍是固定快照而非常青指针。这意味着 `claude-opus-4-8` 永远指向该次发布，不会自动滚动到下一版——生产环境可放心 pin 版本。4.6 代以前的别名才是会解析到带日期 ID 的便利指针。

Adaptive Thinking（自适应思考）

Opus 4.8/4.7 用自适应思考替代了旧的“扩展思考”开关——由模型自行决定推理深度，`effort` 参数在 Opus 4.8 上默认为 `high`（API 与 Claude Code 全平台）。需要不同档位时显式设置 `effort`。

4.7 起的破坏性约束（4.8 沿用）：非默认的 `temperature` / `top_p` / `top_k` 会返回 `400` 错误；自适应思考替代扩展思考。从 4.7 迁移到 4.8 官方未宣布新的破坏性变更，分词器假定不变。但 4.6→4.7 的分词器变化可能使同样文本多产生最多 35% token。

Opus 4.8 的两个实用改进

- 可缓存最小 token 从 4,096 降到 1,024——短系统提示也能用上缓存了
- **Fast Mode**: 2.5× 速度, \$10/\$50 per MTok, 比旧 Opus 的 fast mode (\$30/\$150) 便宜 3 倍。注意 fast mode 是独立计价

2.3 用 Models API 程序化查询能力

不想硬编码规格? 用 Models API 实时查询: 响应含每个可用模型的 `max_input_tokens`、`max_tokens` 和 `capabilities` 对象。

```
# 列出所有可用模型及其规格
curl https://api.anthropic.com/v1/models \
  -H "x-api-key: $ANTHROPIC_API_KEY" \
  -H "anthropic-version: 2023-06-01"
```

03 API 技术文档

Claude API 的核心是 Messages 端点，外加 Batches、Models、Token Counting 等配套端点。

3.1 端点总览

端点	方法 / 路径	用途
Messages	POST /v1/messages	核心对话/生成端点
Message Batches	POST /v1/messages/batches	异步批量，成本立减 50%，24h 内处理
Token Counting	POST /v1/messages/count_tokens	发送前预估 token，管理成本与限流
Models	GET /v1/models	列出可用模型及详情

3.2 基础请求结构

```
curl https://api.anthropic.com/v1/messages \
-H "x-api-key: $ANTHROPIC_API_KEY" \
-H "anthropic-version: 2023-06-01" \
-H "content-type: application/json" \
-d '{
  "model": "claude-opus-4-8",
  "max_tokens": 1024,
  "system": "你是一个资深的解决方案工程师。",
  "messages": [
    {"role": "user", "content": "解释提示缓存的工作原理。"}
  ]
}'
```

3.3 核心请求参数

参数	必填	说明
model	是	模型 ID，如 claude-opus-4-8
max_tokens	是	最大输出 token；不计入 OTPM 限流，设高无副作用
messages	是	对话数组，每条含 role (user/assistant) 与 content
system	否	系统提示，定义角色与约束；适合做缓存前缀
tools	否	工具定义数组，启用 function calling
stream	否	true 时走 SSE 流式逐 token 返回
effort	否	自适应思考强度；Opus 4.8 默认 high
temperature	否	⚠️ Opus 4.7+ 非默认值返回 400
stop_sequences	否	遇到指定字符串即停止生成
metadata	否	请求元数据（如 user_id）

3.4 工具调用（Function Calling）

定义工具后，模型会按需返回 tool_use 块，你执行后把结果以 tool_result 回传，模型据此继续。

```
"tools": [{
  "name": "get_weather",
  "description": "查询指定城市的当前天气",
  "input_schema": {
    "type": "object",
    "properties": {
      "city": {"type": "string", "description": "城市名"}
    },
    "required": ["city"]
  }
}]
```

工具编排是 Claude 的强项：在 MCP-Atlas 基准上 Opus 4.7 得 77.3%，领先 GPT-5.4 约 9.2 分、Gemini 3.1 Pro 约 3.4 分——多工具长链路场景优势明显。

3.5 响应结构与错误码

响应 `content` 是块数组（可含 `text`、`tool_use` 等）。每个响应头都带 `request-id`（全局唯一）和 `anthropic-organization-id`。

状态码	含义	处理建议
400	请求无效（如非默认 temperature）	检查参数；移除不支持的采样参数
413	请求体过大（request_too_large）	直连无硬限；Vertex 30MB / Bedrock 20MB
429	触发限流，含 retry-after 头	按 retry-after 退避重试；平滑流量
529	服务过载	指数退避重试

04 限流与服务层级

限流按模型分别计量，分三个维度，且缓存命中的 token 不计入限流——这是吞吐优化的关键。

4.1 三个限流维度

维度	全称	说明
RPM	Requests Per Minute	每分钟请求数
ITPM	Input Tokens Per Minute	每分钟输入 token（多数模型仅计未缓存部分）
OTPM	Output Tokens Per Minute	每分钟输出 token，实时按实际生成计

三个关键机制：① 限流**按模型独立计量**，可同时跑多个模型各自打满；② **缓存命中的输入 token 不计入限流**，且按基础输入价的 10% 计费——有效缓存可大幅提升实际吞吐而无需提额；③ `max_tokens` 不计入 OTPM，OTPM 只按实际产出算，设高值无限流代价。

4.2 使用层级（Usage Tiers）

API 用量被组织成**自动递增的使用层级**——随消费与账期增长自动提额。可在 Claude Console 查看当前限流，或用 Rate Limits API 程序化读取。超限返回 429 并指明触发了哪个维度。


加速限制（Acceleration Limits）：用量陡增也可能触发 429——即便没到层级上限。规避方式：**逐步放量、保持稳定的使用曲线**，不要瞬间灌入大流量。

4.3 服务层级（Service Tiers）

三档主力模型都支持 **Priority Tier**，为延迟敏感的生产负载提供更稳定的容量。标准层适合一般负载，Batch 走异步队列（24h 内）。

05 成本优化：缓存 / 批处理 / 路由

实际账单往往不取决于头部单价，而取决于这三个杠杆叠加。



图：三档模型 API 单价（左）与成本优化杠杆相对标准价的效果（右）

5.1 提示缓存（Prompt Caching）

把固定的长前缀（系统提示、知识库、文档）缓存起来，命中部分按基础输入价 10% 计费（降 90%）且不计入限流。Opus 4.8 把可缓存最小 token 从 4,096 降到 1,024，短提示也能用。

```
# 在 system 或 content 块上标记 cache_control
"system": [{
  "type": "text",
  "text": "<大段固定知识库内容...>",
  "cache_control": {"type": "ephemeral"}
}]
```

最佳用途：系统提示、重复上下文、长文档。在 Usage 页监控缓存命中率以优化策略。

5.2 批处理 Batch API

- 成本立减 50%，适用全模型
- 异步，24 小时内处理完成——不适合实时场景
- 可叠加提示缓存的折扣
- 支持扩展输出 beta（部分模型 300k 输出）

5.3 模型分层路由

官方明确建议：简单任务用 Haiku，多数生产负载用 Sonnet，最复杂推理用 Opus。把负载分类后分别路由，是第一位的成本决策（远比抠微优化重要）。

5.4 成本测算示例

负载（1000万输入 + 200万输出）	模型	标准成本	叠加缓存+批处理后
同一负载，不同模型	Haiku 4.5	约 \$20	可降至约 \$1-4
	Sonnet 4.6	约 \$60	可降至约 \$3-12

	Opus 4.8	约 \$100	可降至约 \$5-20
--	----------	---------	-------------

估算为示意，实际取决于缓存命中率与可批处理比例。给客户算账时代入真实月 token 量。

Managed Agents 计费提醒：按 token + 会话运行时两个维度计费，缓存乘数同样适用；会话内触发网页搜索按 \$10 / 1000 次另计。Agent Teams（多子代理）会成倍消耗——3 个代理的团队约用 7× 单代理 token。

06 Claude Code：安装与配置详解

Agent 式编码工具，可从 CLI、桌面、移动端委派编码任务。以下为安装与配置要点。

6.1 安装与环境

```
# 通过 npm 全局安装
npm install -g @anthropic-ai/claude-code

# 在项目目录启动
cd your-project
claude
```

- **环境要求：**需 Node.js（官方 npm 包 `@anthropic-ai/claude-code`）
- **平台：**命令行、桌面 App、移动 App 均可；可通过移动 App 远程触发
- **鉴权：**可用 Pro/Max 订阅额度，或用 API key 按 token 计费

6.2 计费与额度

方式	计费	说明
Pro (\$20/月)	标准滚动额度	含全部模型 + Claude Code
Max 5× (\$100) / 20× (\$200)	5×/20× 额度 + 优先访问	全天高强度开发不撞限
API（按 token）	Sonnet \$3/\$15、Opus \$5/\$25	可精确预算

官方称 90% 的 Claude Code 用户日活成本低于 \$30。限流按 5 小时滚动窗口；2026 年 5 月付费套餐 Claude Code 限流翻倍并移除 Pro/Max 高峰限流。

6.3 effort 参数

Opus 4.8 上 `effort` 默认 `high`。Claude Code 中可用 `xhigh` 或 `max` 处理更难的任务——更多 token、更好结果，限流已相应提升以适配。

6.4 MCP 配置

Claude Code 可集成 MCP server 接入外部工具与数据源。远程连接器在 Pro/Max/Team/Enterprise 可用；桌面端本地 MCP 任意有桌面 App 的套餐可用。

配置摩擦点：本地 MCP server 需要手动编辑配置文件，是有记录的上手门槛。官方未公布 MCP server 数量或工具调用的硬上限。

6.5 Agent Teams（多代理）

Claude Code 可派生子代理，每个子代理维护自己的上下文窗口、作为独立 Claude 实例运行。**3 代理团队约用 7× 单代理 token**——并行加速的代价是成本成倍上升，规划预算时务必计入。

07 消费端套餐与功能矩阵

所有付费套餐都能用最新模型；区别在用量、协作与合规，而非模型本身。

套餐	价格	额度	关键功能	适合
Free	\$0	最低，每 5–8h 重置	基础对话、网页搜索、Artifacts；部分连接器	试用
Pro	\$20/月	约 5× Free	全模型 + Claude Code（标准额度）；连接器	个人专业用户
Max 5×	\$100/月	5× Pro + 优先	长会话编码/研究	重度用户
Max 20×	\$200/月	20× Pro	全天 Claude Code 不撞限	全职开发者
Team	\$20–30/坐席 (Premium \$100 含 Claude Code)	团队级	SAML SSO、管理后台、共享 Projects、M365；最低 5 席	5–150 人组织
Enterprise	定制	定制	平台费与用量费分离；最高合规/审计；量价折扣	大型组织

额度按滚动窗口（Free/Pro 约 5–8h，Max 含周级窗口）；官方不公布精确消息条数，随模型/提示长度/附件浮动。价格时点 2026 年 6 月，以官网为准。

订阅 vs API 的分水岭：需要"可精确预算的成本"→ API（按 token）；需要"人坐屏幕前交互使用"→ 订阅。需要 SSO 强制/数据驻留/审计 → Enterprise；只需共享 Projects + 管理后台 → Team。

08 应用层功能详解

套餐之外，Claude.ai 界面本身的能力，逐项含优缺点。

Artifacts（工件）

侧栏实时渲染并运行 React 组件、HTML/CSS、SVG、Mermaid 图、数据可视化、文档草稿。

优点

- 从想法到可跑原型最快路径之一
- 渲染为真实 UI，适合早期评审
- 非技术用户也能产出交互工具

缺点（工程化天花板）

- 不能部署/托管，仅预览
- 不能连后端/数据库
- 限单文件、无持久存储
- 约到"可用 app 的 70%"，剩余需专业开发

Projects（项目）

持久上下文容器：系统提示 + 知识文档 + 工件库。Team 及以上可组织内共享。

优点

- 团队协作核心载体
- 免重复交代背景
- 工件可沉淀复用

缺点

- 项目文件可能占满上下文窗口，挤压对话空间
- 文件多需主动维护命名/归档

连接器 / MCP

开放标准（"AI 的 USB-C"），接入 Gmail、Drive、Slack、GitHub、Notion 等。2026 年 5 月已有 200+ server。

优点

- 开放标准，生态扩张快
- 叠加最强工具编排能力
- 一次接入多处复用

缺点

- 本地 server 需改配置文件，门槛高
- 无公布的硬上限，规划缺边界

应用类代理：Excel / Word / Chrome / Cowork

Excel（2025/10 beta，单元格级引用 + 保留公式）、Word（2026/04，Pro/Max）、Chrome 浏览代理、Cowork 桌面知识工作代理（工件保存最长 90 天）。

优点

- AI 进入 Office/浏览器原生工作流
- Excel 保留公式实用
- Cowork 让非技术用户跑多步流程

缺点

- 多为 beta/预览，仍在成熟
- Computer Use 类有出错可能、需人工监督
- 功能与套餐变动频繁

全局结构性限制：Claude 是"文字+图像输入、文字输出"模型，**无原生图像/音频/视频生成**。需配合 Midjourney/DALL-E 等。这是与 ChatGPT、Gemini 最根本的产品差异。

09 分发渠道与数据合规

模型是同一批，渠道决定合规边界、数据驻留与计费归属。

9.1 四条分发渠道

渠道	模型 ID 风格	请求体上限	核心价值
Anthropic 直连	claude-opus-4-8	无硬限（413 保护）	第一时间拿新模型/功能
AWS Bedrock	anthropic.claude-...	20 MB	并入 AWS 账单与 IAM；含全局/区域端点
Google Vertex AI	claude-opus-4-8	30 MB	并入 GCP；含全局/多区域/区域端点
Microsoft Foundry	—	—	并入 Azure；Opus 4.8 上下文为 200k
Claude Platform on AWS	同直连	同直连	AWS 上用一方模型 ID + 一方生命周期


9.2 数据驻留与合规

- **EU 多区域处理**：API 侧自 2025/08 支持数据驻留
- **US-only 推理**：合规敏感行业可选（约 1.1× 价格）
- **消费端默认无 EU 驻留**：Claude.ai 推理仍路由到 Anthropic 服务器
- **Team 默认不用对话训练模型**；Enterprise 提供定制 DPA
- **EU AI Act**：高风险系统义务自 2026/08/02 起适用——欧洲客户的合规时间窗


区域端点（Bedrock regional / Vertex regional）可保证数据经特定地理区域路由，全局端点则为最大可用性动态路由。

10 竞品横向对比

2026 年 5 月，三大前沿模型在 6 周内相继发布：GPT-5.5、Gemini 3.5 Flash、Claude Opus 4.8。



图：SWE-bench Pro 是当前最难的真实软件工程基准，Opus 4.8 领先显著



图：多维度横向对比（各家以自报设置为准，仅作方向性参考，非严格对齐）

10.1 关键基准数据

基准	Claude Opus 4.8	GPT-5.5	Gemini 3.5 Flash	说明
SWE-bench Pro	69.2%	58.6%	55.1%	最难真实工程任务，Opus 领先 10.6 分
Terminal-Bench 2.1	74.6%	82.7%	76.2%	命令行任务，GPT 领先
AA 智能指数	61.4	58.0	55.3	聚合指数，Opus 居首
长文检索准确率	97.2%	~92%	~90%	长文档/大代码库优势
FACTS 事实性	91.4%	89.7%	93.2%	Gemini 略胜

10.2 按工作负载选模型

负载类型	推荐	理由
软件工程 / 代码审查 / 多文件重构	Claude Opus 4.8	SWE-bench Pro 第一 + Dynamic Workflows 处理代码库级迁移
终端 / DevOps / CLI 自动化	GPT-5.5	Terminal-Bench 领先
延迟敏感 / 高并发 / 成本极敏感	Gemini 3.5 Flash	约 4× 速度、约 70% 更低成本
长文档 / 合同 / 大代码库	Claude	长文检索准确率最高
需要校准的不确定性 / 不愿编造	Claude	安全优先，倾向 hedge 而非 fabricate

10.3 定价与理念对比

维度	Claude	GPT-5.5	Gemini 3.5 Flash
旗舰输入/输出价	\$5 / \$25 (Opus)	低于 Opus (GPT-4o 系 \$2.5/\$10 量级)	\$1.50 输入 (较旧版涨 10×)
长上下文	1M 标准价不加价	1M (旗舰层)	—
多模态生成	✗ 无原生图/音/视频	✓ 含图像生成	✓ 含多模态
战略理念	诚实 + 校准不确定性	原始 Agent 吞吐 + token 效率	高速 Agent + 触达数十亿用户

一句话定性：Anthropic 押注"诚实与校准的不确定性是生产 AI 的下一前沿"，OpenAI 押注"原始 Agent 吞吐与 token 效率"。在严肃软件工程、长文档、需要可信不编造的场景，Claude 是当前更优选择；在终端自动化、需要多模态生成、极致延迟/成本场景，竞品各有所长。多模型路由（按请求选最优模型）是越来越主流的工程实践。

11 选型决策与整体优缺点

把全文收敛成可执行的决策依据。

11.1 产品选型决策树

需求	选择
个人交互使用、写作/研究	Pro (\$20)
高频长会话、老撞限	Max 5×/20×
小团队协作、共享上下文	Team
SSO 强制 / 数据驻留 / 审计	Enterprise
嵌入自有产品、可精确预算	API
Agent 式编码加速	Claude Code
只能从某云采购	对应云渠道 (Bedrock/Vertex/Foundry)
成本敏感、量大、可异步	Sonnet/Haiku + Batch + 缓存

11.2 按任务选模型

任务	模型
分类/抽取/简单问答/高并发	Haiku 4.5
多数生产负载/聊天/文档处理	Sonnet 4.6 (默认)
复杂 Agent/长文写作/多文件重构	Opus 4.8

11.3 整体优缺点

整体优点 • 编码与工具编排第一梯队 (SWE-bench Pro 第一、MCP 编排领先) • 长文质量与长上下文检索准确率突出 (97.2%) • Opus 降价后旗舰可负担 (\$5/\$25) • 1M 上下文标准价不加价 • 缓存+批处理最多降 95% 成本 • MCP 开放标准生态扩张快 (200+ server) • 模型 ID 固定快照, 版本稳定可 pin	整体缺点 • 无原生多模态生成 (图/音/视频) —— 与 GPT/Gemini 最大差距 • 风格偏保守 + 偏啰嗦, 创意发散可能受限 • 终端/CLI 自动化弱于 GPT-5.5 • 速度/成本在极敏感场景不及 Gemini Flash • 多项亮点功能仍 beta, 需人工监督 • Artifacts 无部署/无后端、Projects 上下文挤占等工程化天花板 • 本地 MCP 配置门槛、分词器迁移成本等运维细节
---	---

11.4 一句话定位

Claude 强在**"文字与代码的深度工作"**——推理、写作、严肃软件工程、工具编排、长上下文、可信不编造；弱在**"多模态生成"**与**"开箱即用的生产级交付"**。它是能力极强的**"思考与构建伙伴"**，而非一键产出多模态成品的平台。选型本质：你的核心工作偏**"想清楚、写出来、搭起来"**，还是偏**"生成多模态内容、极致速度成本"**。

数据时点 2026 年 6 月，旗舰 Claude Opus 4.8。模型规格、API 参数、限流、定价来自 platform.claude.com 官方文档；竞品基准来自第三方测评，各家以自报设置发布，仅作方向性参考。多项功能为 beta 且更新频繁，任何生产或采购决策前请以官方文档（platform.claude.com、support.claude.com）与销售报价为准。本文档供技术学习与内部参考。